

Parte II – Carlos Alexis Vega Torres

Reconocimiento de Dígitos con k-NN y Regresión Logística

1. Introducción

El objetivo de este proyecto es aplicar técnicas de aprendizaje automático para el reconocimiento de dígitos escritos a mano, utilizando el dataset MNIST y una imagen personalizada creada en Paint. Se comparan dos modelos de clasificación: k-Nearest Neighbors (k-NN) y Regresión Logística, evaluando su precisión y capacidad de generalización.

2. Metodología

1. Carga de datos: Se utilizó el dataset MNIST y se prepararon los arreglos de variables independientes (píxeles) y la variable objetivo (dígito).
2. Train/Test Split: Se dividió el dataset en 70% entrenamiento y 30% prueba.
3. Modelo k-NN: Se entrenó un clasificador con 14 vecinos y se evaluó su precisión.
4. Overfit/Underfit: Se calcularon las precisiones de entrenamiento y prueba para valores de k entre 1 y 8, graficando los resultados.
5. Imagen personalizada: Se creó una imagen en Paint, se transformó a 28x28 píxeles y se adaptó al formato requerido por sklearn.
6. Regresión Logística: Se entrenó un modelo de regresión logística y se comparó su desempeño con k-NN.

3. Resultados

Precisión k-NN (14 vecinos): 0.9567

Precisión Regresión Logística: 0.8978

Predicción imagen personalizada con k-NN: El número fue reconocido correctamente como [1].

Predicción imagen personalizada con Regresión Logística: El número fue clasificado como [3], mostrando menor fiabilidad.

Gráfico Overfit/Underfit: La curva de entrenamiento inicia en 1.0 para k=1 y desciende, mientras que la curva de prueba se mantiene estable alrededor de 0.96.

4. Discusión

El modelo k-NN mostró mayor precisión y mejor desempeño en la clasificación de dígitos, tanto en el dataset como en la imagen personalizada. La Regresión Logística, aunque útil, presentó menor precisión y problemas de convergencia, además de clasificar incorrectamente la imagen personalizada. El análisis de overfit/underfit evidenció que valores bajos de k tienden a sobreajustar, mientras que valores moderados ofrecen un equilibrio adecuado.

5. Conclusiones

El modelo k-NN es más adecuado para el reconocimiento de dígitos en este contexto.

La Regresión Logística, aunque válida, requiere ajustes adicionales (más iteraciones, escalado de datos) para mejorar su desempeño.

El ejercicio demuestra la importancia de comparar modelos y analizar fenómenos de sobreajuste y sub-ajuste.