

Proyecto Final de Certificación en Ciencia de Datos

Autor: Carlos Alexis Vega Torres

Título: Análisis Integral de Ventas con SQL, Clustering y Predicción

Introducción

El presente proyecto se desarrolló como parte del proceso de certificación en Ciencia de Datos, con el objetivo de aplicar de manera integral técnicas de limpieza, integración, análisis exploratorio, consultas SQL, clustering y modelos predictivos sobre un conjunto de datos de ventas. La importancia de este trabajo radica en demostrar la capacidad de transformar información cruda en conocimiento estratégico, apoyando la toma de decisiones en áreas de marketing, planeación e inventarios.

La metodología se basó en el método científico, garantizando un proceso ordenado y riguroso: desde la observación inicial de los datos hasta la formulación de hipótesis, experimentación con herramientas estadísticas y de machine learning, análisis de resultados y conclusiones con recomendaciones estratégicas. Además, se complementó con visualizaciones interactivas en Power BI, fortaleciendo la presentación ejecutiva de los hallazgos.

1. Observación

Se observó que los datos de ventas estaban dispersos en diferentes tablas (FACT_SALES, DIM_PRODUCT, DIM_SEGMENT, DIM_CALENDAR y DIM_CATEGORY), con valores nulos y sin integración. Esto dificultaba obtener conclusiones estratégicas sobre desempeño de marcas y regiones.

2. Planteamiento del problema

El reto consiste en transformar datos crudos en un modelo analítico consolidado que permita:

- Identificar patrones de ventas y variabilidad entre regiones.
- Determinar marcas líderes y aquellas con tendencia descendente.
- Segmentar productos según comportamiento de ventas.
- Predecir valores futuros para apoyar decisiones de marketing e inventario.

3. Hipótesis

Si se integran las tablas DIM y FACT en un modelo maestro y se aplican técnicas de exploración, clustering y predicción, entonces será posible:

- Reconocer segmentos de ventas diferenciados.
- Determinar regiones y marcas prioritarias.
- Anticipar tendencias futuras con modelos estadísticos.

4. Experimentación


Se desarrollaron ocho bloques en Python, complementados con dashboards en Power BI:

1. **Exploración inicial de archivos**
2. **Carga y limpieza de datos.**
3. **Unión de tablas.**
4. **Exploración y visualización.**
5. **Consultas SQL.**
6. **Clustering K-Means.**
7. **Predicción Machine Learning.**
8. **Conclusiones y recomendaciones.**
9. **Complemento en Power BI.**

5. Resultados y análisis de gráficas


5.1 Distribución de ventas por valor

El histograma muestra una distribución altamente sesgada a la derecha: la mayoría de las transacciones se concentran en valores bajos, mientras que pocas alcanzan montos elevados. Este patrón refleja la naturaleza del mercado de consumo masivo.




5.2 Distribución de ventas por región

El boxplot evidencia diferencias claras entre regiones: México concentra el mayor volumen de ventas, mientras que AREA 6 presenta la mayor variabilidad y un número significativo de outliers.




5.3 Tendencia de ventas en el tiempo

La serie temporal refleja fluctuaciones importantes entre 2022 y 2023, con picos estacionales y caídas. Estos patrones sugieren que las ventas están influenciadas por factores de mercado y temporada.



5.4 Detección de outliers en ventas



El scatterplot confirma la presencia de valores extremos en regiones como México y AREA 6. Estos outliers representan transacciones atípicas que pueden distorsionar el análisis si no se consideran adecuadamente.



5.5 Clustering K-Means



El método del codo indicó que el número óptimo de clusters es 3. El scatterplot de clusters mostró tres segmentos:

- Cluster 0 → ventas bajas frecuentes.
- Cluster 1 → ventas muy altas (outliers).
- Cluster 2 → ventas medias estables. Este hallazgo permite diseñar estrategias diferenciadas para cada segmento.







5.6 Predicciones de ventas

- **ARIMA para VANISH:** estabilización alrededor de 31,000, lo que sugiere un comportamiento más estable en el futuro.
- **Regresión lineal para LYSOL:** tendencia descendente hacia ~470, confirmando la necesidad de estrategias de retención.



5.7 Power BI



6. Conclusiones generales

- La base de datos se integró correctamente con las tablas DIM y FACT, generando un DataFrame maestro de más de 152,000 registros.
- El análisis exploratorio mostró una distribución sesgada de las ventas: muchas transacciones pequeñas y pocas de gran valor.
- Las regiones presentan diferencias claras: México concentra la mayor parte de las ventas, mientras que AREA 6 mostró mayor variabilidad.
- El clustering K-Means identificó tres segmentos: ventas bajas frecuentes, ventas medias estables y ventas muy altas como outliers.
- Los modelos predictivos confirmaron patrones distintos: VANISH con alta variabilidad estabilizada por ARIMA, y LYSOL con tendencia descendente según regresión lineal.

7. Recomendaciones estratégicas

- Enfocar estrategias de marketing en México y AREA 6, donde se concentra el mayor volumen y variabilidad de ventas.
- Potenciar marcas líderes como CLORALEX y VANISH, que representan la mayor parte del valor total.
- Implementar campañas de retención para marcas con tendencia descendente como LYSOL.
- Aprovechar el clustering para diseñar promociones diferenciadas: descuentos en segmentos de ventas bajas, fidelización en segmentos medios y estrategias premium para los outliers.
- Continuar con modelos predictivos en series de tiempo para anticipar picos estacionales y ajustar inventarios.

8. Cierre del proyecto

El análisis cumplió con todas las fases: limpieza, unión de tablas, exploración, consultas SQL, clustering y predicción. Se generaron evidencias gráficas y estadísticas que respaldan las conclusiones. Las recomendaciones ofrecen un camino claro para la toma de decisiones estratégicas en ventas y marketing.